

你所需要的只是少量移位：为图像分类设计高效的卷积神经网络

21821282 代鹏举

All You Need is a Few Shifts: Designing Efficient Convolutional Neural Networks for Image Classification

Weijie Chen, Di Xie, Yuan Zhang, Shiliang Pu
Hikvision Research Institute, Hangzhou, China

{chenweijie5, xiedi, zhangyuan, pushiliang}@hikvision.com

移位运算是深度可分离卷积的有效替代方法。然而，它的实现方式仍然是瓶颈，即内存移动。为了实现这个方法，引入了一种新颖的基本组件——稀疏移位层(SSL)来构造高效的卷积神经网络。在该体系结构中，基本块仅由 1×1 卷积层组成，对中间特征映射只进行少量移位运算。为了使这一想法可行，在优化过程中引入了移位运算损失，并进一步提出了一种量化感知移位学习方法，使学习的位移对推理更加友好。大量的消融研究表明，只有少量移位运算才足以支持空间信息通信。为了最大限度地发挥 SSL 的作用，重新设计了一种改进的网络结构，以充分利用神经网络(FE-Net)的有限容量。该网络采用 SSL 技术，仅用 563M 的 M 增量就能在 ImageNet 上实现 75.0% 的 top-1 精度。它在精度和实际速度上都超过了其他由深度可分离卷积和 NAS 搜索网络构造的同行。

1、设计思路




Figure 2. The practical runtime analysis. For clear comparison, both batch-normalization and ReLU layers are neglected since they can be merged into convolutional layer for inference. Also data feeding and preprocessing time are not considered here. Results are achieved under Caffe with mini-batch 32. They are averaged from 100 runs. (a) ShiftNet-A [37] on CPU (Intel Xeon E5-2650, atlas). (b) ShiftNet-A on GPU (TITAN X Pascal, CUDA8 and cuDNN5). (c) Shift layers in ShiftNet-A are replaced by depthwise separable convolution layers. (d) Depthwise separable convolution layers with kernel size 5 are replaced by the ones with kernel size 3. (e) ShiftNet-A with 80% shift sparsity on GPU (Shift sparsity denotes the ratio of unshifted feature maps).

如图 2 所示，移位运算在实际运行时上优于深度可分离卷积。为了抑制冗余移位运算，在优化过程中增加了损失。进一步的研究发现，少量移位运算实际上就足以提供空间信息通信。通过移动一小部分特征映射，它可以提供类似的性能。为了区别于其他类型的移位层，作者将这种类型的移位层命名为稀疏移位层(SSL)，如图 1 所示。如图 2 (e)所示，诱导稀疏后可显著减少移位运算占用时间。




Figure 1. The comparison of different shift operations applied to feature maps.

为了避免无意义的内存移动，作者在损失函数中加入位移损失来消除无用的移位运算。此外，它还可以避免移位学习的扩散，因为较大的位移会导致有用的

边界信息丢失，特别是对于分辨率较低的特征映射。为此，作者为 α 和 β 添加 L1 正规化来处置冗余的移位，可表述如下：

$$\begin{aligned} \mathcal{L}_{total} &= \sum_{(x,y)} \mathcal{L}(f(x | W, \alpha, \beta), y) + \lambda \mathcal{R}(\alpha, \beta) \\ \mathcal{R}(\alpha, \beta) &= \|\alpha\|_1 + \|\beta\|_1 \end{aligned} \quad (4)$$

其中 (x, y) 是输入数据及其对应的标签, W 表示除了 α 和 β 可训练的参数, $f(\cdot)$ 输出预测的标签, $\mathcal{L}(\cdot)$ 是神经网络的损失函数, λ 平衡这两个关系。

SSL 的前提是确保移位运算是可学习的。常用的解决方法是将位移由整数松弛为实值，将移位运算放宽为双线性插值，使其可微[16]。然而双线性插值不能带来与移位运算相同的推理中的优势。借鉴 QNN[13]的想法，提出了一种量化感知的移位学习方法，使移位运算可微，同时避免了推理过程中的插值。

在设计紧凑的网络体系结构时，一个简单的指导原则是确保信息流，同时保持特征映射的多样性。作者希望它能在有限的特征空间中包含尽可能丰富的标签相关信息。然而，特征映射往往会分解成一个小子集，不能充分利用有限的特征空间。为了解决这一问题，作者设计了一种新型的网络架构 **FE-Net**，如图 3 所示，随着层数的增加，计算中逐步加入特征映射，在保证多样性的同时，避免了冗余开销。

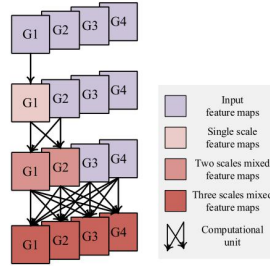


Figure 3. Fully-Exploited computational Block (FE-Block). Only a subset of feature maps is involved into optimization at each basic computational unit. For each resolution, the feature maps are progressively mixed in as layer increases. For a computational block with $n = 3$ basic units as shown in this figure, we evenly divide the input feature maps into 2^{n-1} parts, and involve $\frac{2^l-1}{2^{n-1}}$ ($l = 1, \dots, n$) feature maps into optimization each layer. In this paper, the computational unit is implemented as *inverted bottlenecks* [30].

在这个块中，只有一小部分特征映射被计算进去，其余的直接传送到下一层，以保证信息的流动，可表述如下：

$$\begin{aligned} I_1, I_2 &\leftarrow I \\ O &= f(I_1) \parallel I_2 \end{aligned} \quad (8)$$

其中 I 和 O 表示输入和输出特征映射。 \leftarrow 表示通道方向分裂和 \parallel 表示通道方向连结。采用反向瓶颈[30]作为基本计算单元，构建了如图 4 所示的高效网络。

2、实验

首先对 CIFAR10 和 CIFAR100[18]进行了多次消融实验，以证明 SSL 的效果。然后在 ILSVRC-2012[29]上进行实验，评估其对大规模数据集的泛化能力。

2.1 基准及培训设置

在 CIFAR 上的实验中，选择了由 CSC 模块构建的 ShiftResNet[37]来评估 SSL 的能力。CSC 模块由一个移位层组成，该移位层夹在用于升维的 1×1 卷积神经层和用于降维的 1×1 卷积神经层之间。该模块中只有移位层用于空间信息通信。利用 SSL 替代移位层，通过调整公式 4 中超参数 λ ，研究了至少需要多少移位运算才能维持 ShiftResNet 的性能。




Figure 4. The basic computational units for FE-Block. (a): the basic unit without skipping connection; (b): the basic unit with skipping connection; (c): the basic unit for spatial down sampling ($2 \times$). Note that in (a) and (b), it is SSL that provides receptive fields. (IB is short for inverted bottleneck.)

以 ShiftResNet-20 和 ShiftResNet-56 为代表，以膨胀率 6 为代表进行消融研究。作者使用两个 GPU 对这些网络进行训练，它们的最小批量为 128，基本学习率为 0.1。与[37]相同，经过 32k 和 48k 的迭代，学习速度降低了 10 倍，经过 64k 的迭代，训练停止。具体来说，作者在 48k 次迭代之后停止 SSL 的培训，以修复学习到的移位模式。为了增加数据，只采用水平翻转和随机裁剪。在接下来的实验中，作者使用 L2 正则化来平移值，因为作者发现 L2 正则化的结果略好于 L1。

在 ImageNet 实验中，使用 SGD 对网络进行了小批量 1024、重量衰减 0.00004 和动量 0.9 的训练。训练由学习率 0.6 开始，线性衰减策略，480 个周期后停止，SSL 训练在 240 个周期后停止。整个训练迭代可与[32,22,30,26]相比较。为了增强数据，作者将图像的短边缩放到 256，并采用 224×224 随机裁剪和水平翻转来增强训练数据集。此外，为了进一步丰富训练图像，使用了更多的 Inception training [33, 10]中的失真图像。但它将在最后几个周期被撤回。在验证阶段，只对调整大小的图像进行中心裁剪，并使用单视图方法显示结果。

2.2 消融研究

从三个方面探讨了 SSL 的特性：（i）分组移位对比稀疏移位；（ii）深度网络对比浅层网络；（iii） λ 的设置。

depth	Networks	λ	Accuracy CIFAR10 / CIFAR100	Params / FLOPs	Shift Sparsity CIFAR10 / CIFAR100
20	ResNet [37]	-	91.4% / 66.3%	0.27M / 81M	-
	ShiftResNet (GroupedShift) [37]	-	90.6% / 68.6%	0.16M / 53M	11.1%
	ShiftResNet (SSL)	0	91.7% / 69.2%		12.1% / 10.3%
		1e-4	91.1% / 69.2%		66.6% / 41.2%
		4e-4	90.4% / 67.7%		91.7% / 80.0%
		5e-4	89.8% / 67.7%		93.5% / 86.1%
	ShiftResNet (1x1 only)	-	81.5% / 56.7%		100%
56	ResNet [37]	-	92.0% / 69.3%	0.86M / 251M	-
	ShiftResNet (GroupedShift) [37]	-	92.7% / 72.1%	0.55M / 166M	11.1%
	ShiftResNet (SSL)	0	93.8% / 72.4%		12.8% / 11.4%
		1e-4	92.9% / 71.7%		87.8% / 73.8%
		4e-4	91.9% / 71.1%		97.4% / 94.6%
		5e-4	91.8% / 69.9%		98.0% / 96.1%
	ShiftResNet (1x1 only)	-	82.5% / 56.1%		100%

Table 1. The analysis of SSL on CIFAR10 and CIFAR100

分组移位对比稀疏移位。如表 1 所示，在没有移位损失的情况下，在 CIFAR10 和 CIFAR100 上，移位学习的结果都优于启发式设置。通过移位学习，网络可以根据不同的任务和不同的数据集，自适应地调整移位和移位运算的方向。该算法在保证网络精度与原网络相当的前提下，减少了大量的移位运算。即使在移位运算稀疏度超过 90% 的情况下，网络仍能保持较好的性能，说明只有少数移位运算在图像分类的空间信息交流中起着至关重要的作用。

深度网络对比浅层网络。作者分析了 CIFAR10 / CIFAR100 上 SSL 的稀疏性，包括一个浅网络和一个更深的网络，如 ShiftResNet-20 和 ShiftResNet-56。如表 1 所示，ShiftResNet-56 上的移位稀疏性大于 ShiftResNet-20。它可以在 CIFAR10 / CIFAR100 上提供良好的性能，在 ShiftResNet-56 上的稀疏性甚至超过 95%。增加深度会给移位层带来更多的冗余。

λ 的设置。作者增加 λ 从 0 到 5e-4，发现大部分的移位运算逐步消除，而网络的准确性下降。SSL ($\lambda = 0$) 实际上是相当于量化感知主动移位。当作者显著增加 λ ，把所有的位移都压缩到零，这意味着基本模块都由 1×1 卷积神经层组成，网络中只有 3 个采样层提供空间信息通信。在这种情况下，精度下降了很多，这从另一个方面反映了这样的几个变化对空间信息通信真的很重要。让作者以

CIFAR100 上的 ShiftResNet-56 为例。其精度可由 56.1% 提高到 69.9%，仅移位 3.9% 的特征映射。

2.3 个案研究

设置 $\lambda = 5e-4$ 采取 ShiftResNet-20 在 CIFAR10 和 CIFAR100 上进行更详细的研究。在表 2 中，详细地展示了每一层的移位稀疏性，根据表 2 中最不重要的移位层的稀疏性去除它们。如表 3 所示，当逐步移除最不重要的移位层时，精度只下降了一点点。

Block	CIFAR10		CIFAR100	
	Unshifts/ Channels	Shift Sparsity	Unshifts/ Channels	Shift Sparsity
block1.1	93 / 96	96.9%	82 / 96	85.4%
block1.2	87 / 96	90.6%	84 / 96	87.5%
block1.3	94 / 96	97.9%	92 / 96	95.8%
block2.1	96 / 96	100%	96 / 96	100%
block2.2	161 / 192	83.9%	146 / 192	76.0%
block2.3	181 / 192	94.3%	164 / 192	85.4%
block3.1	190 / 192	99.0%	189 / 192	98.4%
block3.2	331 / 384	86.2%	316 / 384	82.3%
block3.3	382 / 384	99.5%	319 / 384	83.1%
Total	1615 / 1728	93.5%	1488 / 1728	86.1%

Table 2. The shift sparsity of each layer in ShiftResNet-20 ($\lambda = 0.0005$) on CIFAR10 and CIFAR100.

Removed shift layer number (ShiftResNet20-SSL, $\lambda=0$)	Accuracy CIFAR10/CIFAR100
0	91.7% / 69.2%
4	91.5% / 68.2%
6	91.4% / 67.0%
8	89.4% / 66.0%
9 (All removed)	81.5% / 56.7%

Table 3. The performance of ShiftResNet-20 on CIFAR10 and CIFAR100 after removing the most unimportant shift layers.

2.4 在 ImageNet 上的表现

重新设计的 ImageNet2012 分级任务网络架构如表 4 所示，主要由配备 SSL 的 FE-Block 组成。使用宽度乘法器作为超参数来调整精度和计算成本之间的权衡。

Input	Operator	t	n	c	s
$224^2 \times 3$	conv $3 \times 3 + \text{BN}$	-	-	16	2
$112^2 \times 16$	IB-SSL	4	-	16	1
$112^2 \times 16$	IB-Pool 2×2	5	-	32	2
$56^2 \times 32$	FE-Block	6	3	64	2
$28^2 \times 64$	FE-Block	6	4	128	2
$14^2 \times 128$	FE-Block	6	4	128	1
$14^2 \times 128$	FE-Block	6	4	256	2
$7^2 \times 256$	FE-Block	6	3	256	1
$7^2 \times 256$	conv $1 \times 1 + \text{BN} + \text{ReLU}$	-	-	1380	1
$7^2 \times 1380$	GAP 7×7	-	-	1380	-
$1^2 \times 1380$	Dropout 0.2	-	-	1380	-
$1^2 \times 1380$	conv 1×1	-	-	1000	1

Table 4. Network configuration. t denotes expansion rate. n means the computational unit number of FE-Block. c denotes the output channels. And s means stride.

Networks	MAdds	Params	Top-1
MobileNetV1 0.75x [10]	325M	2.6M	68.4%
MobileNetV2 1.0x [30]	300M	3.4M	72.0%
ShuffleNetV1 1.5x (g=3) [40]	292M	3.4M	69.0%
ShuffleNetV2 1.5x [26]	299M	3.5M	72.6%
IGCV3-D [32]	318M	3.6M	72.2%
CondenseNet (G=C=8) [12]	274M	2.9M	71.0%
ShiftNet-B [37]	371M	1.1M	61.2%
AS-ResNet-w50 [16]	404M	1.96M	69.9%
FE-Net (ours) 1.0x	301M	3.7M	72.9%
MobileNetV1 1.0x [10]	569M	4.2M	70.6%
MobileNetV2 1.4x [30]	585M	6.9M	74.7%
ShuffleNetV1 2x [40]	524M	5.4M	70.9%
ShuffleNetV2 2x [26]	591M	7.4M	74.9%
IGCV3-D 1.4x [32]	610M	7.2M	74.55%
CondenseNet (G=C=4) [12]	529M	4.8M	73.8%
PNASNet [22]	588M	5.1M	74.2%
DARTS [23]	595M	4.9M	73.1%
ShiftNet-A [37]	1400M	4.1M	70.1%
AS-ResNet-w68 [16]	729M	3.42M	72.2%
FE-Net (ours) 1.375x	563M	5.9M	75.0%

Table 5. The performance comparison of several compact neural architectures on ImageNet.

与其他同行进行比较。如表 5 所示，随着网络架构的改进，该网络的结果大大超过了 ShiftNet 和 AS-ResNet。

在实际运行时，主要将该网络与 MobileNetV2 进行比较，MobileNetV2 是由深度可分离卷积构造的最具代表性的紧凑网络。如图 6 所示，该网络在 GPU 和 CPU 上的推理时间显著加快，达到了更高的精度，证明 SSL 是更适合实际应用场景的基础组件。

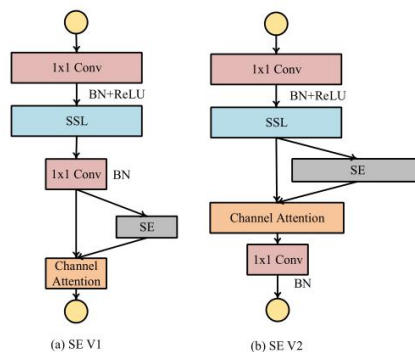



Figure 6. Practical runtime comparison with MobileNetV2. Figure 7. Two different placement manners of SE module.

FE-Net 消融研究。作者还在 ImageNet 上训练了具有深度可分离卷积(DW)的 FE-Net，从改进的网络设计中分解出 SSL 的好处。如表 6 所示，SSL 与基于 DW 的 FE-Net 之间的精度差距较小，但它们的实际运行时要大得多，进一步验证了 SSL 与 FE-Net 的优越性。

Networks	Top1	Top5	GPU	CPU
FE-Net	72.9%	91.2%	16.1ms	1.9s
FE-Net (DW)	73.2%	91.4%	21.8ms	2.7s
FE-Net 1.375x	75.0%	92.4%	23.1ms	3.8s
FE-Net 1.375x (DW)	75.2%	92.8%	30.4ms	5.3s

Table 6. An ablation study of FE-Net with shift operation (SSL) vs. depthwise convolution (DW) on ImageNet (batchsize 32).

该网络还可以与其他方法相结合，以进一步探索性能。

3、结论

作者主要对图像分类基准进行实验。对 CIFAR-10 和 CIFAR100 的广泛消融研究证实了 SSL 的影响。此外，在大型图像分类数据集 ImageNet 上进行了实验，验证了 SSL 的有效性和泛化性。随着网络架构的改进，大幅度的超过了 ShiftNet 和 AS-ResNet[16]。而且这个网络甚至超越了由深度可分离卷积构成的其他同行。在 ImageNet 上实现了 75.0% 的 top-1 精度，增加了 563M 的 M 增量。这是紧凑网络第一次在不使用深度可分离卷积的情况下，在这种计算成本水平上达到如此高的精度。正确地配置压缩激励模块[11]，可使网络的精度进一步提高到 76.5%，增加 566M 的 M 增量。

4、总结

概括起来，其主要贡献如下：

(1) 提出了一种新的基于稀疏移位层的神经网络基本组件，该组件能够快速、准确地消除无意义的内存移动。除此之外，通过大量的消融研究，发现只有少量的移位运算能够提供足够的空间信息通信，这将激发对紧凑神经网络发展的更多探索。

(2) 提出了一种量化感知的移位学习方法，保证了移位运算的可学习性，同时避免了推理过程中的插值。

(3) 为了充分利用有限的特征空间，设计了一种改进的紧凑网络结构。将其与 SSL 相结合，在分类基准测试方面取得了最先进的结果，包括准确性和推理速度。